

합격에 영양 만점

ADsP 요약노트

반복 출제되는
최빈출 개념

기출분석을 기반으로
시험에 나온! 나올! 것만 모았다

데이터 이해

DIKW 피라미드

1 DIKW 피라미드


데이터, 정보, 지식을 통해 최종적으로 지혜를 얻어내는 과정을 계층구조로 설명하는 것

- 데이터를 가공 처리하여 얻을 수 있는 것 : 정보, 지식, 지혜
- Data → Information → Knowledge → Wisdom 계층구조

2 DIKW의 의미

- 데이터(Data): 타 데이터와의 상관관계가 없는 **가공하기 전**의 순수한 수치나 기호
- 정보(Information): 데이터의 가공 및 상관관계 간의 이해를 통해 패턴을 인식하고, 그 의미를 부여한 데이터
- 지식(Knowledge): 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물
- 지혜(Wisdom): **근본 원리에 대한 깊은 이해**를 바탕으로 도출되는 **아이디어**

DIKW 피라미드



데이터베이스 이해

1 데이터베이스(DB; Database)의 정의

- 데이터베이스는 데이터를 저장 및 검색할 수 있는 복합체로 정의됨. 이때 데이터는 **정형뿐만 아니라 비정형 데이터**를 포함
- 초기에는 텍스트, 숫자 형태의 데이터를 있는 그대로 저장하는 장치를 의미(정형 데이터)
- 정보기술의 발달 후 저장되는 데이터가 이미지, 동영상을 포함한 멀티미디어로 확대(비정형 데이터)
- 이후 단순한 데이터 저장에서 정보를 저장하는 지식 베이스로 진화

2 데이터베이스의 특징

통합 데이터(Integrated)	데이터베이스는 같은 내용의 데이터가 중복되어 있지 않음
저장 데이터(Stored)	자기디스크나 자기테이프 등과 같이 컴퓨터가 접근할 수 있는 저장 매체에 저장됨
공용 데이터(Shared)	여러 사용자에게 서로 다른 목적으로 데이터베이스의 데이터가 공동으로 이용됨
변화되는 데이터(Changed)	새로운 데이터의 추가, 기존 데이터의 삭제, 갱신으로 항상 변화하면서도 항상 현재의 정확한 데이터를 유지해야 함

최민호 노론자

04

분야별 기업 내부 데이터베이스 솔루션

1 제조부문 기업 내부 데이터베이스 솔루션

데이터 웨어하우스 (Data Warehouse)	- 기업 내 의사결정 지원 애플리케이션을 위한 정보를 제공하는 하나의 통합된 데이터 저장 공간 - 데이터 웨어하우스(Data Warehouse)의 4대 특징 - 데이터의 통합: 데이터들은 전사적 차원에서 일관된 형식으로 정의됨 - 데이터의 시계열성: 관리되는 데이터들은 시간의 흐름에 따라 변화하는 값을 저장함 - 데이터 주제 지향적: 특정 주제에 따라 데이터들이 분류, 저장, 관리됨 - 비소멸성(비휘발성): Batch 작업에 의한 갱신 이외에 변하지 않음(빈번한 삽입, 삭제 아님)
데이터 마트 (Data Mart)	전사적으로 구축된 데이터 웨어하우스로부터 특정 주제, 부서 중심으로 구축된 소규모 단일 주제의 데이터 웨어하우스
ERP(Enterprise Resource Planning)	제조업을 포함한 다양한 비즈니스 분야에서 주요 프로세스 관리를 돕는 여러 모듈로 구성된 통합 애플리케이션 소프트웨어 패키지
BI와 BA	- BI(Business Intelligence) - 기업의 데이터 웨어하우스(Data Warehouse)에 저장된 데이터에 접근해 경영 의사결정에 필요한 정보를 획득하고 이를 경영활동에 활용하는 것 - 데이터를 통합·분석하여 기업 활동에 연관된 의사결정을 돕는 프로세스를 의미 - 하나의 특정 비즈니스 질문에 답변하도록 설계됨 - 가트너(Gartner)는 '여러 곳에 산재하여 있는 데이터를 수집하여 체계적이고 일목요연하게 정리함으로써 사용자가 필요로 하는 정보를 정확한 시간에 제공할 수 있는 환경'으로 정의함 - 관련 키워드: ad hoc report - BA(Business Analytics) - 경영 의사결정을 위한 통계적이고 수학적인 분석에 초점을 둔 기법으로, 성과에 대한 이해와 비즈니스 통찰력에 초점을 둔 분석 방법 - 사전에 예측하고 최적화하기 위한 것으로, BI보다 진보된 형태 - 관련 키워드: Optimization, Forecast, Insight

2 금융 부문 기업 내부 데이터베이스 솔루션

- 블록체인(Block Chain): 기존 금융회사의 중앙 집중형 서버에 거래 기록을 보관하는 방식에서 벗어나, 거래에 참여하는 모든 사용자에게 거래 내용을 보내주며 거래 때마다 이를 대조하는 데이터 위조 방지 기술
- 그 외 EAI, EDW, ERP, e-CRM 등

빅데이터의 3V와 4V

- 빅데이터의 3V: Volume, Variety, Velocity[가트너(Gartner)가 정의한 빅데이터의 대표적인 특징]
- 빅데이터의 4V: 3V+Value(ROI; Return On Investment, 투자자본수익률 관점에서 보는 빅데이터)

Volume	• 데이터의 크기를 의미함 • 조직 내·외부에서 생성되는 모든 데이터를 저장하고 활용하려는 특성 • 구글 실시간 자동 번역 시스템에 적용되는 빅데이터의 특징임
Variety	• 데이터의 형태와 출처의 다양성을 의미함 • 정형화된 데이터를 넘어 텍스트, 오디오, 비디오와 같은 비정형 데이터 및 웹 문서와 같은 반정형 데이터를 대상으로 함 • 데이터를 정형, 반정형, 비정형으로 나누는 빅데이터의 특징임
Velocity	• 데이터가 생성되고 분석되는 속도를 의미함 • 사용자의 의사결정 시점에 맞추어 데이터를 실시간 또는 준 실시간으로 처리·분석할 수 있어야 함
Value	• 빅데이터로부터 얻을 수 있는 잠재적 가치 또는 비즈니스 인사이트를 의미함 • Value: 비즈니스 효과 요소 • Volume, Variety, Velocity: 투자 비용 요소

빅데이터의 가치와 영향

1 빅데이터 가치 산정이 어려운 이유

- 데이터의 활용 방식: 재사용이나 재조합, 다목적용 데이터 개발 등이 일반화되면서 특정 데이터를 언제, 어디서, 누가 활용할지 알 수 없음
- 새로운 가치 창출: 데이터가 기존에 없던 가치를 창출함에 따라 그 가치를 측정하기 어려움
- 분석 기술의 발달: 분석 기술의 발달로 지금은 가치 없는 데이터도 새로운 분석 기법의 등장으로 거대한 가치를 만들어내는 재료가 될 가능성이 있음

2 빅데이터가 만들어내는 본질적인 변화

사전 처리	사후 처리	• 사전 처리 → 표준화된 문서 포맷 • 사후 처리 → 데이터를 모은 뒤 그 안에서 숨은 정보를 찾아냄 • 구글의 자동 번역 시스템 구축 과정은 데이터의 양이 질보다 중요함을 보여주는 대표적인 사례임
표본 조사	전수 조사	
질(Quality)	양(Quantity)	
인과관계(Causation)	상관관계(Correlation)	

1 빅데이터의 위기 요인

빅데이터의 위기 요인에는 **사생활 침해**, **책임 원칙의 훼손**, **데이터의 오용** 등이 있음

위기 요인	통제 방안
사생활 침해	정보 제공자의 동의제에서 정보 사용자의 책임제로 전환
책임 원칙의 훼손	기존 책임 원칙의 강화
데이터 오용	알고리즘에 대한 접근권 및 객관적 인증 방안 도입

2 사생활 침해

• 위기 요인

- 우리를 둘러싼 정보 수집 센서들의 수가 점점 늘어나고 있고, 이를 통해 수집된 특정 데이터가 본래 목적 외에 가공 처리되어 2차, 3차적 목적으로 활용될 가능성이 증가하고 있음
- 사생활 침해를 방지하기 위해 **익명화 기술**이 발전하고 있으나 아직 충분하지 않음

• 통제 방안

- 정보 제공자의 **동의제**에서 정보 사용자의 **책임제로 전환**
- 개인정보의 활용에 대해 개인이 매번 동의하는 것은 경제적으로도 매우 비효율적임
- 사생활 침해 문제를 개인정보 제공자의 동의를 통해 해결하기보다는 **개인정보 사용자에게 책임을 지움**으로써, 개인정보 사용 주체가 더 적극적인 보호 장치를 마련하게 하는 효과가 발생할 것으로 기대됨

3 책임 원칙의 훼손

• 위기 요인

- 빅데이터 기반의 분석과 예측 기술이 발전하면서 정확도가 증가한 만큼, 분석 대상이 되는 사람들은 예측 알고리즘의 희생양이 될 가능성이 증가함
- 잠재적 위험 사항에 대해서도 책임을 추궁하는 사회로 변질될 가능성이 높아 민주주의 사회 원칙을 크게 훼손할 수 있음

예시 범죄 예측 프로그램을 통해 범죄가 발생하기 전 체포, 회사의 직원 해고, 의사의 환자 수술 거절, 어떤 사람이 특정한 사회·경제적 특성을 가진 집단에 속한다는 이유로 신용도와 무관하게 대출이 거절되는 상황 등

• 통제 방안

- **기존의 책임 원칙 보강 및 강화**
- 결과 기반의 책임 원칙 고수
- 예측 자료에 의해 불이익을 당할 가능성을 최소화하는 장치 마련

4 데이터의 오용

• 위기 요인

- 빅데이터는 일어난 일에 대한 데이터에 의존함
- 그것을 바탕으로 미래를 예측하는 것은 적지 않은 정확도를 가질 수 있지만 항상 맞을 수는 없음
- 주어진 데이터로부터 잘못된 인사이트를 얻어 비즈니스에 직접 손실을 불러올 수 있음

- 통제 방안
 - 데이터 알고리즘에 대한 접근권을 허용해야 함
 - 객관적인 인증 방안을 도입해야 한다는 필요성이 제기되고 있음

더 보기

알고리즘리스트(Algorithmist)

- 데이터의 오용으로 인한 부당한 피해를 보는 사람을 방지하기 위해 생겨난 직업으로, 데이터 분석 알고리즘으로 인해 불이익을 당한 사람을 구제하는 전문가
- 법률 전문가인 변호인, 금전 거래에 정통한 회계사처럼 컴퓨터와 수학, 나아가 통계학이나 비즈니스에 두루 깊은 지식을 갖춘 사람이 이 직업을 담당하게 됨

09

데이터 사이언스(Data Science)

1 데이터 사이언스의 정의

- 데이터로부터 의미 있는 정보를 추출하는 학문
- 정형, 반정형, 비정형 등 다양한 유형의 데이터를 대상으로 함
- 분석뿐만 아니라 이를 효과적으로 구현하고 전달하는 과정까지 포함한 포괄적 개념
- 데이터 공학, 수학, 통계학, 컴퓨터 공학, 시각화, 해커의 사고방식, 해당 분야의 전문 지식을 종합한 학문
- 기존의 통계학과 다르게 총체적(Holistic) 접근법 사용

2 데이터 사이언스의 핵심 구성 요소

- IT 영역(Data Management): 시그널 프로세싱, 데이터 엔지니어링, 데이터 웨어하우스, 프로그래밍, 고성능 컴퓨터 등
- 분석 영역(Analytics): 수학, 확률 모델, 머신러닝, 분석학, 패턴 인식과 학습, 불확실성 모델링 등
- 비즈니스 컨설팅 영역: 커뮤니케이션, 프레젠테이션, 스토리텔링, 시각화 등

3 데이터 사이언스와 다른 학문과의 차이점

구분	데이터 사이언스	통계학	데이터 마이닝
분석 대상	정형, 비정형, 반정형 등 다양한 데이터 유형	정형화된 데이터	–
분석 방법	분석+시각화+전달을 포함한 포괄적 개념	–	분석에 초점
학문 접근	종합적 학문 또는 총체적 접근법	–	–

09

데이터 분석 관련 직무

1 데이터 분석 관련 직무별 필요 역량

- 데이터 분석가
 - 데이터 분석 보고서 및 시각화 자료를 통해 비즈니스 결정에서 '추측'에 의한 결정을 없앨 수 있도록 해주고, 서로 다른 팀 간의 중재자 역할을 함

- 조직의 성장에 대한 정확한 지표를 확인하고, 데이터 기반 의사결정을 위해 통계적 데이터 분석을 하며, 분석 결과를 시각화함
- 필요 역량으로 문맥과 의미, 통찰력, 이론적 지식, 비즈니스·도메인 지식, 데이터 시각화 역량, 데이터 분석을 위한 통계적 지식, SQL 지식 등이 있음

• 데이터 사이언티스트

- 통찰력 있는 분석과 설득력 있는 전달을 할 수 있어야 하고, 다분야 간의 협력을 통해 빅데이터의 가치를 실현하는 역할을 함
- 머신러닝, AI에 대한 지식, 머신러닝 모델 구축을 위한 기본적인 언어를 사용한 코딩 스킬, 데이터 분석을 위한 통계적 지식 등의 능력이 필요함

• 데이터 분석가와 데이터 사이언티스트의 필요 역량

- 데이터 사이언티스트와 데이터 분석가의 필요 능력은 비슷한 부분이 많음
- 데이터 사이언티스트는 데이터 분석가보다 머신러닝, AI에 대한 많은 지식을 바탕으로 모델을 구축하고 데이터를 분석하는 능력이 필요함
- 데이터 분석가는 보고서 작성, 시각화, 통찰력, 비즈니스·도메인 지식 등의 능력이 필요함

2 데이터 사이언티스트의 세부 역량

• 가트너(Gartner)가 본 데이터 사이언티스트의 역량

- 데이터 관리, 분석 모델링, 비즈니스 분석, 소프트 스킬 등이 있음
- 공통점은 호기심에서 시작하는 것이며, 하드 스킬은 포함되어 있지 않음

• 일반적으로 언급되는 데이터 사이언티스트의 역량

- 데이터 해커, 애널리스트, 커뮤니케이션, 신뢰받는 어드바이저 등의 조합이라 할 수 있음
- 하드 스킬과 소프트 스킬 능력을 동시에 갖추고 있어야 함
- 데이터 처리 기술 이외에 사고방식, 비즈니스 이슈에 대한 감각, 고객들에 대한 공감 능력이 필요함

3 데이터 사이언티스트가 갖추어야 할 스킬

• 하드 스킬

- Machine Learning, Modeling, Data Technical Skill
- 빅데이터에 대한 이론적 지식: 관련 기법에 대한 이해와 방법론 습득
- 분석 기술에 대한 숙련: 최적의 분석 설계 및 노하우 축적

• 소프트 스킬

- 통찰력 있는 분석: 창의적 사고, 호기심, 논리적 비판
- 설득력 있는 전달: Storytelling, Visualization
- 다분야 간 협력: Communication

4 데이터 사이언티스트가 효과적인 분석 모델 개발을 위해 고려해야 하는 사항

- 분석 모델이 예측할 수 없는 위험을 살피기 위해 현실 세계를 돌아보고 분석을 경험과 세상에 대한 통찰력과 함께 활용해야 함
- 가정들과 현실의 불일치에 대해 끊임없이 고찰하고 모델의 능력에 대해 항상 의구심을 갖는 것이 필요함
- 분석의 객관성에 의문을 제기하고 분석 모델에 포함된 가정과 해석의 개입 등의 한계를 고려해야 함
- 모델 범위 바깥의 요인은 판단하지 말아야 함

데이터 분석 기획


분석 기획 - 분석 주제 유형 4가지

분석 방법 (How)	분석 대상(What)	
	Known	Un-Known
Known	최적화(Optimization)	통찰(Insight)
Un-Known	솔루션(Solution)	발견(Discovery)


최적화(Optimization)	분석 대상 및 분석 방법을 이해하고 현 문제를 최적화된 형태로 분석 과제를 수행함
솔루션(Solution)	분석 대상은 알고, 분석 방법은 알지 못하는 경우 솔루션을 찾는 방식으로 수행함
통찰(Insight)	- 분석 대상이 불분명하나, 분석 방법은 알고 있는 경우 사용함 - 기본 분석 방식을 활용하여 통찰(Insight)을 도출해냄으로써 문제의 도출 및 해결에 기여함
발견(Discovery)	분석 대상, 방법을 모른다면 발견을 통해 분석 대상 자체를 새롭게 도출함

KDD, CRISP-DM


1 KDD 분석 방법론 (5단계)




2 CRISP-DM 분석 방법론(6단계)



3 CRISP-DM 분석 방법론 - 업무 이해 순서



1 빅데이터 분석 방법론 5단계 절차



2 위험에 대한 대응 계획 수립

- 회피: 계획 변경 등 원인을 제거하는 것(기간 연장, 범위 축소)
- 전이: 보험, 사후 보증
- 완화: 용인 가능 임계치까지 절감하려 노력하는 것
- 수용: 적극적 수용(긴급 대책), 소극적 수용(아무 조치 안 함), Fallback Plan(위험의 영향이 클 경우)

1 상향식 접근 방식(Bottom-Up Approach)

- 문제의 정의 자체가 어려운 경우에 사용
- 데이터 기반으로 문제의 재정의 및 해결 방안을 탐색하고 이를 지속적으로 개선하는 방식
- 주로 비지도학습(Unsupervised Learning) 방법에 의해 수행됨
- 디자인 사고(Design Thinking)의 발산 단계에 해당함
- 분석 주제가 통찰(Insight), 발견(Discovery)일 때 효과적인 방법

예시 | 새로운 신제품 개발 프로젝트, 새로운 고객군 발굴

2 하향식 접근 방식(Top-Down Approach)

- 문제가 명확하게 정의되어 있을 때 적합한 방식
- 주어진 문제의 해법을 찾기 위해 각 단계를 체계적으로 수행하는 방식
- 전통적으로 수행되었던 분석 과제 발굴 방식
- 분석 주제가 최적화(Optimization), 솔루션(Solution)일 때 효과적인 방법

예시 | 신제품을 위한 마케팅 전략 수립, 이탈 고객 재유치 방안 설계

3 디자인 사고(Design Thinking)

- 최근 복잡하고 불확실한 문제에 충분히 대응하기 어려운 기존의 전통적 분석 방식의 한계를 극복하기 위한 접근법
- 가능한 옵션을 도출하는 **상향식 접근 방식의 발산(Diverge) 단계**와 도출된 옵션을 분석하고 검증하는 **하향식 접근 방식의 수렴(Converge) 단계**를 반복하여 과제를 발굴

예시 고객 이탈률 감소를 위한 은행의 서비스 개선, 신상품 컨셉 설계

더 보기

비지도 학습

입력만 제시되고, 결과값이 제시되지 않은 데이터로, 진행하는 학습으로 주성분 분석, 군집 분석, 연관 분석 등이 있음

전통적 분석 방식

- 문제를 해결하고 결정을 내리는 데 있어서 **과학적이고 논리적인 분석을 중시하는 사고 방식**
- 현실적이고 합리적인 접근 방식으로 주로 수학, 과학, 엔지니어링, 경제학 등의 분야에서 효과적으로 활용되고 있음
- 창의적인 해결책을 찾는 데 한계가 있을 수 있음

16


하향식 접근 방법의 데이터 기획 단계

1 하향식 접근 방식의 데이터 분석 기획 단계

하향식 접근 방식의 데이터 분석 기획 단계는 ‘문제 탐색 → 문제 정의 → 해결 방안 탐색 → 타당성 검토’ 순으로 진행됨

2 문제 탐색(Problem Discovery)

- 문제 탐색 개요
 - **전체적인 관점의 기준 모델을 활용**하여 빠짐없이 문제를 도출하고 식별
 - 문제 탐색(과제 발굴) 단계에서는 **문제를 해결함으로써 발생하는 가치에 중점**을 두는 것이 중요
 - 문제 탐색 단계에는 **비즈니스 모델 기반 문제 탐색, 외부 참조 모델 기반 문제 탐색, 분석 유즈케이스 정의**가 있음
- 비즈니스 모델 기반 문제 탐색
 - 비즈니스 모델 캔버스는 기업의 사업 모델을 도식화한 비즈니스 모델 캔버스의 9가지 블록을 ‘**업무, 제품, 고객, 규제와 감사, 지원 인프라**’의 5가지 영역으로 단순화한 것
 - 비즈니스 모델 캔버스: 과제 발굴을 위한 기본 틀로서 비즈니스에 포함되어야 하는 주요 사업 요소를 한눈에 볼 수 있도록 만든 그래픽 템플릿
 - **분석 기회 발굴의 범위 확장**: 새로운 문제의 발굴 및 장기적인 접근을 위해서는 기업이 현재 수행하고 있는 비즈니스뿐만 아니라 **환경과 경쟁 구도의 변화 및 역량의 재해석**을 통한 **혁신(Innovation)**의 관점에서 **분석 기회를 추가 도출**하는 것이 요구됨



• 외부 참조 모델 기반 문제 탐색

- 유사·동종 사례 벤치마킹을 통해 분석 기회를 발굴
- 데이터 분석 사례를 기반으로 분석 테마 후보 그룹을 미리 정의하고, 그 후보 그룹을 통해 해당 기업에서 벤치마킹할 대상인 분석 기회를 고려하면 **빠르고 쉽게 분석 기회를 도출**할 수 있음
- 유사·동종 업계뿐만 아니라 **타 업종 및 다른 분야의 데이터 분석 활용 사례를 정리**해 놓으면 새로운 주제 탐색에 도움이 됨

• 분석 유즈케이스 정의

- 현재의 비즈니스 모델 및 유사·동종 사례 탐색을 통해 빠짐없이 도출한 분석 기회들을 구체적인 과제로 만들기에 앞서 분석 유즈케이스로 표기하는 것이 필요함
- 풀어야 할 문제에 대한 상세 설명 및 해당 문제를 해결했을 때 발생하는 효과를 명시하고, 향후 데이터 분석 문제로의 전환 및 적합성 평가에 분석 유즈케이스를 활용하도록 함

3 문제 정의(Problem Definition)

식별된 비즈니스 문제를 데이터의 문제로 변환하여 정의하는 단계

4 해결 방안 탐색(Solution Search)

어떤 데이터 또는 분석 시스템을 사용할 것인지 검토하는 단계

5 타당성 검토 단계(Feasibility Study)


- 타당성 검토를 통해 **프로젝트나 계획의 실현 가능성과 효과성**을 평가하고, 필요한 조치나 수정 사항을 식별하여 **프로젝트가 계획대로 진행**될 수 있도록 함
- 도출한 데이터 분석 문제 및 선정된 솔루션 방안을 포함하며, **분석 과제 정의서**의 형태를 명시하는 후속 작업을 시행하고 프로젝트 계획 수립의 입력물로 활용할 수 있음

최민호의 데이터 분석

17

분석 과제 우선순위 결정

1 분석 우선순위 평가 기준




- 데이터 분석 과제를 추진할 때 우선 고려해야 하는 요소는 **전략적 중요도에 따른 시급성**이 가장 중요한 기준임
- 데이터를 생성, 저장, 가공, 분석하는 비용과 현재 기업의 분석 수준을 고려한 **난이도** 역시 **적용 우선순위를 선정하는 데 있어 중요한 기준**이 될 수 있음
- 시급성의 판단 기준은 전략적 중요도가 핵심이며, 이는 **현재의 관점에 전략적 가치를 둘 것인지 미래의 중장기적 관점에 전략적인 가치를 둘 것인지에** **적정 시기를 고려**하여 시급성 여부를 판단할 수 있음
- 난이도는 현 시점에서 과제를 추진하는 것이 비용 측면과 데이터 적용 범위 측면에서 바로 적용하기 쉬운(Easy) 것인지 또는 어려운(Difficult) 것인지에 대한 판단 기준임

2 분석 과제 우선순위 선정 매트릭스

1사분면(현재, Difficult) - 전략적 중요도가 높아 경영에 미치는 영향이 크므로 현재 시급하게 추진이 필요함 - 난이도가 높아 바로 적용하기 어려움	2사분면(미래, Difficult) - 전략적 중요도가 낮지만 반드시 추진되어야 하는 중장기 과제 - 난이도가 높아 바로 적용하기 어려움
3사분면(현재, Easy) - 전략적 중요도가 높아 현재 시급하게 추진이 필요함 - 난이도가 낮아 바로 적용 가능함 가장 우선순위가 높음	4사분면(미래, Easy) - 전략적 중요도가 낮은 중장기 과제 - 난이도가 낮아 바로 적용 가능함

3 포트폴리오 사분면을 통한 과제 우선순위 선정



- 일반적으로 가장 먼저 수행해야 하는 것은 3사분면에 해당하는 과제
- 우선순위를 '시급성'에 둔다면 'Ⅲ - Ⅳ - Ⅱ' 순서로 과제 진행. 우선순위를 '난이도'에 둔다면 'Ⅲ - Ⅰ - Ⅱ' 순서로 과제 진행
- 시급성이 높고(현재) 난이도가 높은(Difficult) 영역(1사분면)은 경영진 또는 실무 담당자의 의사결정에 따라 적용 우선순위 조정 가능

최민호 노은자

18

데이터 분석 수준 진단

1 데이터 분석 준비도(Readiness)

- 기업의 데이터 분석 도입의 수준을 파악하기 위한 진단 방법으로 6가지 영역을 대상으로 현 수준을 파악함
- 분석 준비도의 6가지 영역: 분석 업무 파악, 인력 및 조직, 분석 기법, 분석 데이터, 분석 문화, IT 인프라(=분석 인프라)

분석 업무 파악	인력 및 조직	분석 기법
- 발생한 사실 분석 업무 - 예측 분석 업무 - 시뮬레이션 분석 업무 - 최적화 분석 업무 - 분석 업무 정기적 개선	- 분석 전문가 직무 존재 - 분석 전문가 교육 훈련 프로그램 - 관리자의 기본 분석 능력 - 전사 분석 업무 총괄 조직 존재 - 경영진 분석 업무 이해 능력	- 업무별 적합한 분석 기법 사용 - 분석 업무 도입 방법론 - 분석 기법 라이브러리 - 분석 기법의 효과성 평가 - 분석 기법의 정기적 개선
분석 데이터	분석 문화	IT 인프라(=분석 인프라)
- 분석 업무를 위한 데이터 충실성 - 분석 업무를 위한 데이터 신뢰성 - 분석 업무를 위한 데이터 적시성 - 비구조적 데이터 관리 - 외부 데이터 활용 체계 - 기준 데이터 관리	- 사실에 근거한 의사결정 - 관리자의 데이터 중시 - 회의 등에서 데이터 활용 - 경영진의 직관보다 데이터 활용 - 데이터 공유 및 협업 문화	- 운영 시스템 데이터 통합 - EAI, ETL 등 데이터 유통 체계 - 분석 전용 서버 및 스토리지 - 빅데이터 분석 환경 - 비주얼 분석 환경

2 분석 성숙도(Maturity)

- 시스템 개발 업무 능력과 조직의 성숙도 파악을 위해 CMMI 모델을 기반으로 분석 성숙도를 평가함
- **비즈니스, 조직·역량, IT** 부문을 대상으로 성숙도 수준에 따라 **도입, 활용, 확산, 최적화** 단계로 구분해 살펴볼 수 있음
- 데이터 분석 성숙도 수준에 따른 단계

단계	도입	활용	확산	최적화
설명	분석을 시작하여 환경과 시스템 구축	분석 결과를 실제 업무에 적용	전사 차원에서 분석을 관리하고 공유	분석을 진화시켜 혁신 및 성과 향상에 기여
비즈니스 부문	• 실적 분석 및 통계 • 정기 보고 수행 • 운영 데이터 기반	• 미래 결과 예측 • 시뮬레이션 • 운영 데이터 기반	• 전사 성과 실시간 분석 • 프로세스 혁신 3.0 • 분석 규칙 관리 • 이벤트 관리	• 외부환경 분석 활용 • 최적화 업무 적용 • 실시간 분석 • 비즈니스 모델 진화
조직· 역량 부문	• 일부 부서에서 수행 • 담당자 역량에 의존	• 전문 담당 부서에서 수행 • 분석 기법 도입 • 관리자가 분석 수행	• 전사 모든 부서 수행 • 분석 CoE 조직 운영 • 데이터 사이언티스트 확보	• 데이터 사이언스 그룹 • 경영진 분석 활용 • 전략 연계
IT 부문	• 데이터 웨어하우스 • 데이터 마트 • ETL/EAI, OLAP	• 실시간 대시보드 • 통계 분석 환경	• 빅데이터 관리 환경 • 시뮬레이션·최적화 • 비주얼 분석 • 분석 전용 서버	• 분석 협업 환경 • 분석 Sandbox • 프로세스 내재화 • 빅데이터 분석

최빈출 노선

19

데이터 거버넌스 체계 수립

1 데이터 거버넌스

- 전사 차원의 모든 데이터에 대해 정책 및 지침, 표준화, 운영 조직 및 책임 등의 표준화된 관리 체계를 수립하고 운영을 위한 프레임워크(Framework) 및 저장소(Repository)를 구축하는 것
- 마스터데이터(Masterdata), 메타 데이터(Meta Data), 데이터 사전(Data Dictionary)은 데이터 거버넌스의 중요한 관리 대상임
- 기업은 데이터 거버넌스 체계를 구축함으로써 데이터의 가용성, 유용성, 통합성, 보안성, 안정성을 확보할 수 있음
- 빅데이터 프로젝트를 성공으로 이끄는 기반이 됨
- 데이터 거버넌스는 독자적으로 수행될 수도 있지만 **전사 차원의 IT 거버넌스나 EA(Enterprise Architecture)의 구성 요소**로서 구축되는 경우도 있음
- 데이터 표준 및 정책에 따라 데이터를 생성·변경하고 데이터의 품질과 보안 등 **전사 차원의 데이터 관리 체계**를 구축하는 것

2 데이터 거버넌스 구성 요소

- 원칙(Principle): 데이터를 유지 관리하기 위한 지침과 가이드 **예시** 보안, 품질 기준, 변경 관리
- 조직(Organization): 데이터를 관리할 조직의 역할과 책임 **예시** 데이터 관리자, 데이터베이스 관리자, 데이터 아키텍트
- 프로세스(Process): 데이터 관리를 위한 활동과 체계 **예시** 작업 절차, 모니터링 활동, 측정 활동

3 데이터 거버넌스 체계 요소

- 데이터 거버넌스 체계 요소 이해

데이터 표준화	데이터 표준 용어 설정, 명명 규칙 수립, 메타 데이터 구축, 데이터 사전 구축
데이터 관리 체계	메타 데이터와 데이터 사전(Data Dictionary)의 관리 원칙 수립
데이터 저장소 관리	메타 데이터 및 표준 데이터를 관리하기 위한 전사 차원의 저장소를 구성
표준화 활동	데이터 거버넌스 체계 구축 후, 표준 준수 여부를 주기적으로 점검, 모니터링

- 데이터 거버넌스의 데이터 저장소 관리
 - 메타 데이터 및 표준 데이터를 관리하기 위한 **전사 차원의 저장소를 구성**
 - 저장소는 데이터 관리 체계 지원을 위한 워크플로우 및 관리용 응용 소프트웨어를 지원하고 관리 대상 시스템과의 인터페이스를 통한 통제가 이루어져야 함
 - 데이터 구조 변경에 따른 **사전영향평가**도 수행되어야 효율적인 활용이 가능함

4 빅데이터 거버넌스의 특징

- 기업이 가진 과거 및 현재의 모든 데이터를 분석하여 비즈니스 인사이트를 찾는 노력은 비용면에서 효율적이지 못함
→ **분석 대상 및 목적을 명확히 정의**하고, 필요한 데이터를 수집, 분석하여 점진적으로 확대해 나가는 것이 좋음
- 빅데이터 분석에서 품질관리도 중요하지만, **데이터 수명주기 관리방안을 수립**하지 않으면 데이터 가용성 및 관리 비용 증대 문제에 직면할 수 있음
- ERD는 운영 중인 데이터베이스와 일치하기 위해 **계속해서 변경사항을 관리**하여야 함
- 산업 분야별, 데이터 유형별, 정보 거버넌스 요소별로 **구분하여 작성**함
- 적합한 분석 업무를 도출하고 가치를 높여줄 수 있도록 분석 조직 및 인력에 대해 **지속적인 교육과 훈련**을 실시함
- **개인정보 보호 및 보안**에 대한 방법을 마련해야 함


최민준 특강

19

데이터 분석을 위한 조직 구조

1 집중형 조직 구조

- 조직 내 **별도 독립적인 분석 전담 조직**을 구성하여 분석 전담 조직에서 **회사의 모든 분석 업무를 담당**함
- 전사 분석 과제의 전략적 중요도에 따라 우선순위를 정해 추진함
- 일부 협업 부서와 분석 업무가 중복 또는 이원화될 가능성이 있음



집중형 조직 구조

2 기능 중심 조직 구조

- 일반적인 분석 수행 구조로, **별도 분석 조직을 구성하지 않고 각 해당 업무 부서에서 직접 분석**함
- **전사적 관점에서 핵심 분석이 어려움**
- 특정 업무 부서에 국한된 분석 수행 가능성이 높거나 일부 중복된 분석 업무를 수행할 수 있음



기능 중심 조직 구조

3 분산 조직 구조

- **분석 조직의 인력들이 협업 부서에 배치되어 업무를 수행**함
- 전사 차원에서 분석 과제의 우선순위를 선정해 수행이 가능함
- 분석 결과를 신속하게 실무에 적용이 가능함
- 부서 분석 업무와 역할 분담을 명확히 해야 함



분산 조직 구조

1 분석 프로젝트의 특징

- 분석가의 목표는 분석의 정확도를 높이는 것이지만 프로젝트의 관점에서는 도출된 분석 과제를 잘 구현하여 원하는 결과를 얻고 사용자가 원활하게 활용할 수 있도록 전체적인 과정을 고려해야 하므로 개별적인 분석 업무 수행뿐만 아니라 전반적인 프로젝트 관리도 중요함
- 분석 프로젝트에서는 데이터 영역과 비즈니스 영역의 현황을 이해하고 프로젝트의 목표인 분석의 정확도 달성과 결과에 대한 이해를 전달하는 조정자로서의 분석가 역할이 중요함
- 분석 프로젝트는 도출된 결과의 재해석을 통한 지속적인 반복 및 정교화가 수행되는 경우가 대부분이므로 프로토타이핑 방식의 애자일(Agile) 프로젝트 관리 방식도 고려해야 함
- 분석 과제 정의서를 기반으로 분석 프로젝트를 시작하되 지속적인 개선 및 변경을 염두에 두고 시간 내에 최선의 결과를 도출할 수 있도록 프로젝트 구성원들과 협업하여 진행해야 함
- 다양한 데이터에 기반한 분석 기법을 적용하는 특성 때문에 5가지 주요 특성을 고려하여 추가적인 관리가 필요함
- 분석 과제 주요 특성 관리 영역: Data Size, Data Complexity, Speed, Analytic Complexity, Accuracy & Precision 등
- 분석 프로젝트는 다른 프로젝트 유형처럼 범위, 일정, 품질, 리스크, 의사소통 등 영역별 관리가 수행되어야 함

더 보기

Agile 프로젝트 관리 방식

- 소프트웨어 개발 및 다른 프로젝트 영역에서 사용되는 반복적이고 유연한 접근 방식
- 변화에 빠르게 대응하고 고객 요구 사항을 우선적으로 고려하는 민첩한 프로젝트 관리 방법론, 불확실한 환경에서 효과적

2 분석 과제 정의서

- 다양한 분석 과제 도출 방법을 통해 도출된 분석 과제를 분석 과제 정의서로 정리함
- 필요한 소스 데이터, 분석 방법, 데이터 입수 난이도, 데이터 입수 사유, 분석 수행 주기, 분석 결과에 대한 검증, 분석 과정 상세 등을 작성함
- 프로젝트 수행 계획의 입력물로 사용됨
- 이해관계자가 프로젝트의 방향을 설정하고, 성공 여부를 판별할 수 있는 중요한 자료로 명확하게 작성해야 함

3 분석 과제의 5가지 특성 관리 영역

Data Size	분석하고자 하는 데이터의 양을 고려하는 관리방안 수립이 필요함
Data Complexity	비정형 데이터 및 다양한 시스템에 산재되어 있는 데이터들을 통합해서 분석 프로젝트를 진행할 때는 해당 데이터에 잘 적용될 수 있는 분석 모델 선정에 대한 고려가 필요함
Speed	• 분석 결과 도출 후, 활용하는 시나리오 측면에서 일, 주 단위 실적은 배치 형태로 작업, 사기 탐지, 서비스 추천은 실시간 수행되어야 함 • 분석 모델의 성능 및 속도를 고려한 개발 및 테스트가 수행되어야 함
Analytic Complexity	• 정확도(Accuracy)와 복잡도(Complexity)는 트레이드 오프(Trade-off) 관계가 존재 • 분석 모델이 복잡할수록 정확도는 올라가지만 해석이 어려워짐 • 기준점을 사전에 정의해 두어야 함
Accuracy & Precision	• 정확도(Accuracy): 분석의 활용적인 측면(모델과 실제값의 차이) • 정밀도(Precision): 분석의 안정성 측면(모델을 반복했을 때의 편차) • 정확도(Accuracy), 정밀도(Precision)는 트레이드 오프인 경우가 많음 • 모델의 해석 및 적용 시 사전에 고려해야 함

4 10개 주제별 프로젝트 관리 체계

분석 프로젝트는 시간, 범위, 품질, 통합, 이해관계자, 자원, 원가, 리스크, 조달, 의사소통과 같은 관리 영역에서 일반 프로젝트와 다르게 유의해야 할 요소가 존재함

시간	- 초기에 의도했던 결과가 나오기 쉽지 않아 지속적으로 반복되어 많은 시간이 소요될 수 있음 - 분석 결과에 대한 품질이 보장된다는 것을 전제하여 Time Boxing 기법으로 일정 관리를 진행하는 것이 필요함
범위	- 프로젝트 범위가 분석을 진행하면서 데이터의 형태와 양 또는 적용되는 모델의 알고리즘에 따라 범위가 빈번하게 변경됨 - 분석의 최종 결과물이 분석 보고서 형태인지, 시스템인지에 따라 투입되는 자원 및 범위가 크게 변경되므로 사전에 충분한 고려가 필요함
품질	품질 보증과 품질 통제를 계획하고 확립하는 데 요구되는 프로세스
통합	프로젝트와 관련된 다양한 활동과 프로세스를 도출, 정의, 결합, 단일화, 조정, 통제, 종료에 필요한 프로세스
이해관계자	프로젝트 스폰서, 고객사, 기타 이해관계자 식별 및 관리에 필요한 프로세스
자원	인력, 시설, 장비, 자재, 기반 시설, 도구와 같은 적절한 프로젝트 자원을 식별하고 확보하는 데 필요한 프로세스
원가	개발 예산과 원가 통제의 진척 상황을 관찰하는 데 요구되는 프로세스
리스크	위험과 기회를 식별하고 관리하는 프로세스
조달	계획에 요구된 프로세스를 포함하며, 제품 및 서비스 또는 인도물을 인수하고 공급자와의 관계를 관리하는 데 요구되는 프로세스, 목적에 맞게 적절한 아웃소싱 필요
의사소통	프로젝트와 관련된 정보를 계획, 관리, 배포하는 데 요구되는 프로세스

데이터 분석

R함수 - summary

1 iris 데이터셋

```
> summary(iris)

      Sepal.Length      Sepal.Width      Petal.Length      Petal.Width
Min.   : 4.300      Min.   : 2.000      Min.   : 1.000      Min.   : 0.100
1st Qu.: 5.100      1st Qu.: 2.800      1st Qu.: 1.600      1st Qu.: 0.300
Median : 5.800      Median : 3.000      Median : 4.350      Median : 1.300
Mean   : 5.843      Mean   : 3.057      Mean   : 3.758      Mean   : 1.199
3rd Qu.: 6.400      3rd Qu.: 3.300      3rd Qu.: 5.100      3rd Qu.: 1.800
Max.   : 7.900      Max.   : 4.400      Max.   : 6.900      Max.   : 2.500

      Species
setosa   : 50
versicolor : 50
virginica : 50
```

• 연속형 변수

- 연속형 변수명: Sepal.Length, Sepal.Width, Petal.Length, Petal.Width
- Sepal.Width를 통해 “2.8보다 크거나 같은 값을 갖는 데이터가 75%이다.”, “3.0보다 크거나 같은 값을 갖는 데이터가 50%이다.”, “3.3보다 크거나 같은 값을 갖는 데이터가 25%이다.”의 내용을 추론할 수 있음

• 범주형 변수

- 범주형 변수명: Species
- setosa, versicolor, virginica의 3개 범주가 있으며, 각 범주별로 50개씩 총 150개의 데이터가 있음

• NA's: iris 데이터셋에는 결측값이 없음

2 hitters 데이터셋

```
> summary(hitters) 일부

League Division PutOuts Assists Errors
A:175      E:157      Min.   : 0.0      Min.   : 0.0      Min.   : 0.00
N:147      W:165      1st Qu.: 109.2    1st Qu.: 7.0      1st Qu.: 3.00
                          Median : 212.0    Median : 39.5     Median : 6.00
                          Mean   : 288.9    Mean  : 106.9     Mean   : 8.04
                          3rd Qu.: 325.0    3rd Qu.: 166.0    3rd Qu.: 11.00
                          Max.   : 1378.0   Max.   : 492.0     Max.   : 32.00

      Salary      NewLeague
Min.   : 67.5      A:176
1st Qu.: 190.0     N:146
Median : 425.0
Mean   : 535.9
3rd Qu.: 750.0
Max.   : 2460.0
NA's   : 59
```

• 연속형 변수: PutOuts, Assists, Errors, Salary

• 범주형 변수

- 범주형 변수명: League, Division, NewLeague

- 총 322개의 데이터가 있음

• NA's

- Salary변수에 59개의 결측값이 존재함. 결측값은 NA's : 59로 표시됨

3 Orange 데이터셋

```
> summary(Orange)
```

Tree	age	circumference
3:7	Min. : 118.0	Min. : 30.0
1:7	1st Qu. : 484.0	1st Qu. : 65.5
5:7	Median : 1004.0	Median : 115.0
2:7	Mean : 922.1	Mean : 115.9
4:7	3rd Qu. : 1372.0	3rd Qu. : 161.5
	Max. : 1582.0	Max. : 214.0

• 연속형 변수

– 연속형 변수명: age, circumference

– age의 평균: 922.1

– circumference의 Median을 봤을 때 115.0이므로, 약 50%의 나무는 115보다 큰 둘레를 가지고 있음


• 범주형 변수

– 35개의 관측치를 포함함(Tree의 종류는 5가지이며, 각각 7개씩임)

– Tree는 factor 타입이며 '3 → 1 → 5 → 2 → 4' 순서로 되어 있음

24

그래프 종류 - 상자 그림(Boxplot)



• Min, Q1, Median, Q3, Max 값과 이상값(Outlier)을 확인할 수 있음

• Min, Max는 일반적인 범위(이상값 범위 안쪽)에서 가장 작은 값과 큰 값을 의미하므로 Min, Max 값까지 연결된 선(=수염)의 길이는 대칭이 아닐 수 있음

• Q1, Q3는 각각 제1사분위수, 제3사분위수를 의미하며 25%, 75% 위치를 나타냄

• IQR은 사분위수 범위라고 하여 $Q3 - Q1$ 으로 구함

• 이상값의 기준이 되는 하한은 $Q1 - 1.5 \times IQR$, 상한은 $Q3 + 1.5 \times IQR$

• 하한보다 작은 값이거나 상한보다 큰 값은 이상값으로, 그래프에서 동그라미로 표시됨

• Median은 중앙값을 의미하고, 50% 위치를 나타냄

• 상자 그림에 평균, 분산, 데이터의 개수 등의 정보는 들어있지 않음

1 이상값 개요

- 일반적인 다른 값과 멀리 떨어져 있는 값(거리, 밀도)
- 이상값은 정형 데이터보다 반정형, 비정형 데이터에서 많이 발생
- 분포를 왜곡할 수 있으나 실제 오류인지 통계적으로 검증할 수 없으므로 제거 여부는 해당 분야의 전문가 또는 실무자와 상의하여 판단해야 함
- 이상값도 분석의 대상이 될 수 있어 반드시 제거해야 하는 것은 아니며, 분석의 목적이나 종류에 따라 적절한 판단이 필요함
- 이상값을 활용한 시스템에는 '부정 사용 방지 시스템' 등이 있음

2 이상값 탐지

- ESD(Extreme Studentized Deviation) 방법
 - 정규분포에서 나온 표본값일 경우, 평균과 표준 편차를 사용하여 이상값을 탐색하기 위한 통계적 방법
 - 평균으로부터 T 표준 편차(Standard Deviation) 이상 떨어져 있는 값들을 이상값(Outlier)으로 판단하고, T는 3으로 설정하는 이상값 검색 알고리즘

$$\mu - 3\sigma < \text{정상 데이터} < \mu + 3\sigma$$

μ : 평균, σ : 표준 편차

- 사분위수(Quartile) 방법: Q1, Q3 및 IQR을 사용해서 이상값을 탐색하는 방법으로 상자 그림(Boxplot)에서 사용

$$(Q1 - 1.5 \times IQR) < \text{정상 데이터} < (Q3 + 1.5 \times IQR)$$

Q1: 제1사분위수, Q3: 제3사분위수, IQR = Q3 - Q1(IQR: 데이터의 가운데 50%)


- summary 함수: summary 함수의 결과로 표시되는 Q1, Q3값을 보고 판단하는 방법으로 Q1, Q3를 사용하여 IQR을 구하고, Q1, Q3, IQR을 사용해 lower, upper의 범위를 구함

3 이상값 처리 방법

- 이상값 제거
 - 이상값이 데이터 오류나 노이즈일 경우, 해당 값을 제거함
 - 분석의 신뢰도를 높일 수 있지만, 중요한 정보일 가능성이 있는 이상값을 제거하면 데이터가 왜곡될 수 있음
 - 데이터를 삭제하면 정보손실이 높아짐. 특히 데이터의 수가 적을 때 유용한 정보도 함께 손실될 수 있어 신중히 사용해야 함
- 데이터 변환
 - 이상값이 데이터의 분포에 큰 영향을 준다면 로그 변환, 제곱근 변환 등을 통해 분포를 정규화할 수 있음
 - 다만, 해석이 어려워지며 변환이 모든 모델에 적합한 것은 아님
- 이상값 절단(capping)
 - 이상값을 특정 임계값으로 제한하는 방법으로 하한 및 상한값을 설정하여 이상값을 해당 값으로 대체하는 방법
 - 이상값을 절단하면 이상값의 영향을 줄이면서 데이터 손실을 최소화할 수 있지만, 데이터의 분포를 왜곡할 수 있음

1 상관계수의 이해

- 상관계수는 두 변수의 **관련성의 정도**를 의미함(-1 ~ 1의 값으로 나타냄)
- 두 변수의 상관관계가 존재하지 않을 경우 상관계수는 '0'임



- 상관관계가 높다고 인과관계가 있다고 할 수는 없음
- 피어슨 상관계수와 스피어만 상관계수가 있음
- 피어슨 상관계수는 두 변수 간의 **선형적인 크기만 측정 가능**하며 스피어만 상관계수는 두 변수 간의 **비선형적인 관계도 나타낼 수 있음**
- R의 `cor.test()` 함수를 사용해 상관계수 검정을 수행하고, 유의성 검정을 판단할 수 있음
- 이때 귀무가설은 "상관계수는 0이다."이고, 대립가설은 "상관계수는 0이 아니다."임

2 공분산

- 2개 확률변수의 선형관계를 나타내는 값

• 모집단의 공분산 $cov(x, y) = \frac{\sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)}{N}$, 표본의 공분산 $cov(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1}$

- 하나의 변수가 상승하는 경향을 보일 때 다른 값도 상승하는 **선형 상관성**이 있다면 **양의 공분산**을 가짐
- 두 확률변수 x, y가 **독립**이면 **공분산 cov(x, y)=0**이며, 관측값들이 4면에 균일하게 분포되어 있다고 추정할 수 있음
- cov(x, y)=0이라고 해서 항상 두 확률변수 x, y가 독립인 것은 아님

3 피어슨 상관계수와 스피어만 상관계수

- 피어슨 상관계수(Pearson correlation)

- x, y의 공분산을 x, y의 표준 편차의 곱으로 나눈 값

- 모집단의 경우: $corr(x, y) = \frac{cov(x, y)}{\sigma_x \sigma_y}$

- 표본의 경우: $corr(x, y) = \frac{cov(x, y)}{s_x s_y}$

- 대상 자료는 **등간척도**, **비율척도**를 사용함
- 두 변수 간의 **선형적인 크기만 측정 가능**

- 스피어만 상관계수(Spearman correlation)

- **서열척도**인 자료에서 사용 가능함
- 두 변수 간의 **비선형적인 관계**를 나타낼 수 있음
- 두 변수의 순위 사이의 통계적 의존성을 측정하는 비모수적인 척도, 연속형 외에 **이산형도 가능**함
- 스피어만 상관계수는 원시 데이터가 아니라 **각 변수에 대해 순위를 매긴 값을 기반으로 함**
- 두 변수 간의 순위가 완전 일치하면 1, 완전 반대이면 -1

예시 수학을 잘하는 학생이 영어도 잘하는 것과 상관있는지 알아보는 데 사용될 수 있음

4 피어슨 상관계수 구하기

- 응답자1의 표준 편차 2, 응답자2의 표준 편차 2, 두 응답자의 공분산 값이 4일 때 피어슨 상관계수는?




$$\text{피어슨 상관계수}(p): \text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y} = \frac{\text{cov}(x, y)}{S_x S_y} = \frac{4}{4} = 1$$

- 다음 표는 응답자의 키와 몸무게를 나타낸 것이다. 키와 몸무게의 피어슨 상관계수는 얼마인가? (단, 모집단에 대한 값을 구한다)

응답자 ID	키	몸무게
1	165	65
2	170	70
3	175	75
4	180	80
5	185	85

- 피어슨 상관계수(p) = $\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$
- 키의 평균은 175, 표준 편차는 $\sqrt{50}$ 이고, 몸무게의 평균은 75, 표준 편차는 $\sqrt{50}$
- 이때 키와 몸무게의 공분산은 50
- 이를 피어슨 상관계수 식에 대입하면 $\frac{50}{\sqrt{50} \times \sqrt{50}} = 1$

5 스피어만 상관계수 그래프 해석

		
두 변수 X, Y가 선형관계가 아니더라도 스피어만 상관계수는 1이 될 수 있음	데이터가 뚜렷한 경향성을 보이지 않을 경우 스피어만 상관계수와 피어슨 상관계수는 비슷한 값을 가짐	스피어만 상관계수는 피어슨 상관계수에 비해 이상값에 덜 민감함. 이는 스피어만 상관계수가 이상값을 그 값이 아닌 순위로서만 고려하기 때문임

6 상관 분석 예시

```
> Carseats <- read.csv('data/Carseats_dataset.csv', stringsAsFactors=TRUE)
> rcorr(as.matrix(Carseats[, c(1:6, 8)]), type="pearson")
```


	Sales	CompPrice	Income	Advertising	Population	Price	Age
Sales	1.00	0.06	0.15	0.27	0.05	-0.44	-0.23
CompPrice	0.06	1.00	-0.08	-0.02	-0.09	0.58	-0.10
Income	0.15	-0.08	1.00	0.06	-0.01	-0.06	0.00
Advertising	0.27	-0.02	0.06	1.00	0.27	0.04	0.00
Population	0.05	-0.09	-0.01	0.27	1.00	-0.01	-0.04
Price	-0.44	0.58	-0.06	0.04	-0.01	1.00	-0.10
Age	-0.23	-0.10	0.00	0.00	-0.04	-0.10	1.00

n= 400
P

	Sales	CompPrice	Income	Advertising	Population	Price	Age
Sales		0.2009	0.0023	0.0000	0.3140	0.0000	0.0000
CompPrice	0.2009		0.1073	0.6294	0.0584	0.0000	0.0451
Income	0.0023	0.1073		0.2391	0.8752	0.2579	0.9258
Advertising	0.0000	0.6294	0.2391		0.0000	0.3743	0.9276
Population	0.3140	0.0584	0.8752	0.0000		0.8087	0.3948
Price	0.0000	0.0000	0.2579	0.3743	0.8087		0.0411
Age	0.0000	0.0451	0.9258	0.9276	0.3948	0.0411	


- 결과에서 위쪽에 있는 것이 상관계수 행렬, 아래쪽에 있는 것은 상관계수에 대한 p-value 행렬임
- 위쪽에 있는 상관계수 행렬은 상관관계에 대해 보여주는 것으로 -1 ~ 1의 값으로 표시되고 대각선은 1로 채워지며, 두 변수의 교차 지점의 숫자가 상관계수임
- 예를 들어 Price와 Sales는 -0.44이며, 음의 상관관계를 가짐
- 아래쪽에 있는 p-value 행렬을 사용해 위쪽의 상관계수가 통계적으로 유의미한지를 알 수 있음
- 예를 들어 Price와 Sales는 p-value가 0이므로 통계적으로 유의미하며, Sales와 CompPrice, Sales와 Population는 통계적으로 유의미하지 않음
- Sales와 가장 강한 상관관계를 보이는 변수는 Price로, 절댓값을 보았을 때 가장 크기 때문임
- 전체에서 가장 큰 상관관계를 보이는 두 변수는 Price와 CompPrice임

7 그래프로 표시된 상관계수 행렬



- 변수 이름에서 행과 열의 방향으로 있는 숫자를 사용하여 해석함(변수 이름의 교차지점의 숫자가 두 변수의 상관계수임)
- 사각형에 해당하는 0.70은 Examination과 Education변수의 상관계수임


8 원의 크기로 표시된 상관계수 행렬



- 동그라미가 작고 흐리게 표시된 것은 상관계수가 작은 것을 의미, 동그라미가 크고 진하게 표시된 것은 상관계수가 큰 것을 의미
- CAtBat, CHmRun, CRuns, CRBI 등의 독립변수들은 서로 상관관계가 높아 다중공선성의 문제가 발생할 수 있음

9 산점도로 알아보는 상관관계


- 직선의 형태에 가까울수록 -1 또는 1 에 가까운 모양이며, 사분면에 고르게 점이 보이면 상관관계가 없는 것임. 산점도를 통해 상관관계가 있다고 판단되는 두 변수는 단순 선형 회귀 모형 추정이 가능
- 차량 392대의 연비(mpg)와 마력(horsepower)에 관한 그래프



- 연비(MPG)와 마력(Horsepower)은 음의 상관관계이므로 마력이 증가할 때 연비가 감소하는 경향을 볼 수 있음
- 연비와 마력 간에 선형성을 볼 수 있으므로 영향력으로 단순 선형 회귀 모형 추정이 가능함
- 연비, 마력은 비율척도이므로 피어슨 상관계수로 분석이 가능함

1 주성분 분석(PCA, Principal Component Analysis)

- 데이터를 분석할 때 변수의 개수가 많다고 모두 활용하는 것이 꼭 좋은 것은 아님
- 오히려 변수가 '다중공선성'이 있을 경우 분석 결과에 영향을 줄 수도 있음
- 공분산 행렬 또는 상관관계수 행렬을 사용해 모든 변수들을 가장 잘 설명하는 주성분을 찾는 방법
- 상관관계가 있는 변수들을 선형 결합에 의해 상관관계가 없는 새로운 변수(주성분)를 만들고 분산을 극대화하는 변수로 축약함
- 주성분은 변수들의 선형 결합으로 이루어져 있음
- 독립변수들과 주성분과의 거리인 '정보손실량'을 최소화하거나 분산을 최대화함



원본 데이터셋과 투영(projection)된 데이터셋 간의 분산이 최대가 되는 축을 찾는다(그림에서 C1).
 ⇒ "PCA는 데이터의 분산이 최대가 되는 축을 찾는다." = "정보의 손실을 최소화한다."

2 주성분 분석을 할 때 고민해야 하는 것

- 공분산 행렬과 상관관계수 행렬 중 어떤 것을 선택할 것인가?
- 주성분의 개수를 몇 개로 할 것인가?
- 주성분에 영향을 미치는 변수로 어떤 변수를 선택할 것인가?

3 공분산 행렬(default) vs 상관관계수 행렬

- 공분산 행렬은 변수의 측정 단위를 그대로 반영한 것이고, 상관관계수 행렬은 모든 변수의 측정 단위를 표준화한 것임
- 공분산 행렬을 이용한 경우 측정 단위를 그대로 반영하였기 때문에 변수들의 측정 단위에 민감함
- 주성분 분석은 거리를 사용하기 때문에 척도에 영향을 받음(정규화 전후의 결과가 다름)
- 설문조사처럼 모든 변수들이 같은 수준으로 점수화된 경우 공분산 행렬을 사용함
- 변수들의 scale이 서로 많이 다른 경우에는 상관관계수 행렬(correlation matrix)을 사용함

4 주성분 분석에서의 상관관계수 행렬 적용

- `prcomp(data, scale=TRUE)`, `princomp(data, cor=TRUE)`
- `scale`, `cor`을 FALSE로 지정하거나 생략 시 공분산 행렬이 사용됨
- `prcomp`, `princomp`의 결과는 같음

5 주성분 개수 결정 기준

- 성분들이 설명하는 분산의 비율
 - 누적 분산 비율을 확인하면 주성분들이 설명하는 전체 분산 양을 알 수 있음
 - 누적 분산 비율이 70~90% 사이가 되는 주성분 개수 선택

- **고윳값(Eigenvalue)**: 평균 고윳값(각 주성분의 표준 편차를 제곱한 값)들의 평균을 구한 후 고윳값이 평균값 이상이 되는 주성분을 선택
- **스크리 플롯(Scree Plot)**: 고윳값을 가장 큰 값에서 가장 작은 값의 순서로 정렬해 보여줌(1보다 큰 값 사용 또는 Elbow 기법)

```
fit <- prcomp(USArrests, scale=TRUE)
summary(fit)
```

Importance of components:


	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000

fit\$rotation

	PC1	PC2	PC3	PC4
Murder	-0.5358995	0.4181809	-0.3412327	0.64922780
Assault	-0.5831836	0.1879856	-0.2681484	-0.74340748
UrbanPop	-0.2781909	-0.8728062	-0.3780158	0.13387773
Rape	-0.5434321	-0.1673186	0.8177779	0.08902432

- 제1주성분 식: $PC1 = -0.536\text{Murder} - 0.583\text{Assault} - 0.278\text{UrbanPop} - 0.543\text{Rape}$
- 주성분 결과를 보면 PC2의 Cumulative Proportion이 0.8675로 86.75%이므로, 2개의 주성분을 사용함

6 주성분 개수 결정의 예



- [왼쪽] Scree Plot을 보면 Eigenvalue가 1보다 큰 것이 1, 2 주성분이므로 2개의 주성분을 사용함
- [오른쪽] Scree Plot에서 Eigenvalue가 1보다 큰 것을 사용하려면 3개의 주성분을 사용해야 하고, 팔꿈치 부분(각도가 급격하게 완만해지는 부분)을 찾는 Elbow 기법을 사용하여 최적의 요소 수를 찾으려면 4개임

7 주성분 분석 결과 해석

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000

- Standard deviation(표준 편차): 자료의 산포도를 나타내는 수치로, 분산의 양의 제곱근, 표준 편차가 작을수록 평균값에서 변량들의 거리가 가까움
- Proportion of Variance(분산 비율): 각 분산이 전체 분산에서 차지하는 비중
- Cumulative Proportion(누적 비율): 분산의 누적 비율
- 첫 번째 주성분 하나가 전체 분산의 62%를 설명함. 두 번째는 24.7%를 설명함
- 반대로 이야기하면 첫 번째 주성분 부분만 수용했을 때 정보 손실은 $(100-62)=38\%$ 가 됨

최민준 노은자

35

회귀 모형 해석

1 표본 회귀선의 유의성 검정

- 두 변수 사이에 선형관계가 성립하는지 검정함
- 귀무가설과 대립가설
 - 귀무가설: 회귀식의 기울기계수 β_1 은 0과 같음
 - 대립가설: 회귀식의 기울기계수 β_1 은 0과 같지 않음

2 회귀 모형의 해석 방법

- ‘모형이 통계적으로 유의미한가?’ → F-통계량의 유의확률(p-value)로 확인함
- ‘회귀계수들이 통계적으로 유의미한가?’ → 회귀계수의 t 값에 대한 유의확률로 확인함
- ‘모형이 얼마나 설명력을 갖는가?’ → 결정계수(R^2)의 크기로 확인함
- ‘모형이 데이터를 잘 적합하고 있는가?’ → 잔차를 그래프로 그려 회귀 진단을 해야 함
- ‘데이터가 모형 가정을 만족시키는가?’를 확인 → 모형 가정: 선형성, 정규성, 독립성, 등분산성, 비상관성

3 F-통계량

$$F\text{-통계량} = \frac{\text{회귀제곱평균(MSR)}}{\text{잔차제곱평균(MSE)}}$$

- 모형의 통계적 유의성을 검정하기 위한 검정 통계량
- F-통계량이 클수록 회귀 모형은 통계적으로 유의함
- F-통계량에 대한 p-value < 0.05일 때 통계적으로 유의함

4 t 값

$$t \text{ 값} = \frac{\text{Estimate(회귀계수)}}{\text{Std. Error(표준 오차)}}$$

- t-통계량이 크다는 것은 표준 오차가 작다는 것을 의미함
- t-통계량이 클수록 회귀계수가 유의함
- t 값에 대한 p-value < 0.05일 때 통계적으로 유의함

5 결정계수(R²)

$$\text{결정계수}(R^2) = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

- 회귀식의 적합도를 측정하는 척도
- 결정계수는 0~1 사이의 범위를 가지며, 결정계수가 커질수록 회귀방정식의 설명력이 높아짐
- 전체 분산 중 모델에 의해 설명되는 분산의 양

6 회귀 모형의 해석 참고

```
> a <- lm(formula = y ~ u + v + w, data = df)
> summary(a)
```

Call:

lm(formula = y ~ u + v + w, data = df)

Residuals:

Min	1Q	Median	3Q	Max
-1.06096	-0.31857	0.06092	0.32280	1.03220

Coefficients:

t-통계량 = Estimate/std.Error 회귀계수들이 유의미한가?

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3.43742	0.46949	7.322	3.01e-09	***
u	0.46762	0.04419	10.581	6.55e-14	***
v	0.95558	0.04546	21.019	< 2e-16	***
w	-1.99230	0.01052	-189.459	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4695 on 46 degrees of freedom

Multiple R-squared: 0.9988, Adjusted R-squared: 0.9987

F-statistic: 1.254e+04 on 3 and 46 DF, p-value: < 2.2e-16

R²: 모형이 얼마나

설명력을 갖는가?

F-통계량: 모형이 통계적으로 유의미한가?

38

시계열 분석

1 정상성(Stationarity)

- 시계열의 평균과 분산에 체계적인 변화가 없고, 주기적 변동이 없음
- 미래의 확률적 성질이 과거와 동일하다고 가정

2 정상 시계열의 조건

- 평균은 모든 시점(시간 t)에 대해 일정함

$$E(x_t) = \mu$$

- 분산은 모든 시점(시간 t)에 대해 일정함

$$\text{var}(x_t) = \sigma^2$$

- 공분산은 시점(시간 t)에 의존하지 않고, 시차에만 의존함. 공분산은 시차(h)에 의해 결정되고, 특정 시점 t의 영향을 받지 **않음**(시차가 같다면 공분산이 같음)

$$\text{Cov}(x_{t+h}, x_t) = \gamma_h$$

3 정상 시계열 전환

- 비정상 시계열 자료는 정상성을 만족하도록 정상 시계열로 만든 후 시계열 분석을 수행함
- 상황별 시계열 전환

평균이 일정하지 않은 경우	원계열에 차분(Differencing) 적용
계절성을 갖는 비정상 시계열	계절 차분 적용 예 6~8월 판매량이 증가한다면 → 이번 년도 6~8월 판매량 - 이전 년도 6~8월 판매량
분산이 일정하지 않은 경우	원계열에 로그 변환(Log Transformation) 적용
구간 분할(Segmentation)	특정 구간에서 데이터가 정상성을 가질 경우, 해당 구간만 분리하여 분석
이상값 삭제(Outlier Removal)	이상값이 시계열의 정상성을 해칠 경우, 이상값을 제거하여 정상성을 확보하는 방법


4 차분

데이터의 평균이 일정하지 않은 경우, 현재 시점의 값에서 이전 시점의 값을 빼는 작업으로, 이를 통해 추세(Trend)와 계절성(Seasonality)을 제거하여 평균과 분산이 일정한 데이터로 변환함

5 분해 시계열 분해 요인

추세 요인(Trend Factor)	자료의 그래프를 그렸을 때, 그 형태가 오르거나 내리는 등 자료가 어떤 특정한 형태를 취하는 경우
계절 요인(Seasonal Factor)	계절 또는 고정된 주기에 따라 자료가 변화하는 경우 예 1년 중 특정한 때, 일주일의 특정 요일에 나타나는 요인
순환 요인(Cyclical Factor)	물가상승률, 급격한 인구 증가 등 명확한 주기가 없는 변동 요인 으로 자료가 변화하는 경우
불규칙 요인(Irregular Factor)	추세 요인, 계절 요인, 순환 요인의 세 가지 요인으로 설명할 수 없으며, 회귀 분석에서 오차에 해당하는 요인에 의해 발생하는 경우

6 시계열 데이터 분석 절차



7 확률적 시계열 모형

- AR 모형: 백색 잡음의 현재값과 자기 자신의 과거값의 선형 가중값으로 이루어진 정상확률 모형(정상 시계열)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

c : 모형의 평균·추세를 나타내는 상수(회귀 모형의 절편), ϕ : 자기회귀계수, y_{t-1} , y_{t-2} : 자기 자신의 과거 값
 ε_t : 백색 잡음의 현재값, p : 자기회귀의 차수

- MA 모형: 현시점의 자료는 평균과 유한 개의 과거 백색 잡음의 선형 결합으로 표현(정상 시계열)

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim N(0, \sigma^2)$$

c : 모형의 평균을 나타내는 상수, θ : 이동평균계수,
 ε : 백색 잡음(t 는 현재 값, $t-1$ 은 과거 시점을 의미함), q : 이동평균의 차수


- ARIMA 모형: 비정상 시계열 모형이며 차분/변환을 통해 AR, MA, ARMA 모형으로 정상화

최민준 노트

40

모형 평가

1 홀드아웃(Hold-out)의 데이터셋 분리



- Training Data: 학습용 데이터
- Test Data: 학습 종료 후 성능 확인용 데이터
- Validation Data: 학습 중 성능 확인용 데이터(Overfitting 여부 확인, Early Stopping 등을 위해 사용), 반복되는 학습 기법에서 사용되며 몇 번의 반복을 하면서 과대적합이 되는지 확인하거나, 과대적합 발생이 감지되면 빠르게 학습을 멈추기 위해 사용하는 데이터

2 K-Fold 교차검증

- 주어진 데이터를 K 개로 나누고, K 번 반복적으로 학습하고 성과를 측정하여 그 결과를 평균 낸 성능으로 평가하는 방법
- 10 Fold 교차검증
 - K 는 데이터를 동일한 10개 조각으로 나누고, 1개를 검증, 9개를 학습 데이터로 사용함
 - 총 10번 검증을 실시하고 얻은 결과를 평균 내어 최종 결과로 사용함
 - K -Fold 교차검증의 순서

- 전체 데이터를 섞음(Shuffle)
- 데이터를 동일 크기의 K 개로 분할(K 의 최솟값은 2)
- K 번째의 하부 집합은 검증용 자료, $K-1$ 개는 훈련용 자료로 사용하여 K 번 반복한 다음 모델링하고 성능을 측정
- K 개의 결과를 평균 낸 값을 최종 결과로 사용

3 LOOCV(Leave One Out Cross Validation)

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$$

- 데이터 개수를 n 개라고 할 때 n 번의 학습을 진행하고, 그 평가 결과를 평균하여 최종 결과로 사용하는 방식
- 1개 관측값만을 Validation Set으로 사용하고, 나머지 $n-1$ 개를 train Set으로 사용하여 n 번의 학습을 진행
- $k=n$ 인 경우의 교차검증
- 학습 후 계산된 n 개의 MSE(Mean Squared Error)를 평균하여 최종 MSE를 계산

4 부트스트랩(Bootstrap)

- 평가를 반복하는 측면에서 교차검증과 유사하지만, 훈련용 자료를 반복하여 재선정한다는 점에서 차이가 있는 평가 방법
- 부트스트랩은 관측치를 한 번 이상 훈련용 자료로 사용하는 복원 추출법에 기반함
- 전체 데이터 양이 크지 않을 경우의 모형 평가에 가장 적합
- 훈련 데이터를 63.2% 사용하는 0.632 부트스트랩은 훈련에 사용하지 않는 데이터가 36.8%가 되는 것임

최빈종 노드자

42

의사결정나무(Decision Tree) 모형

1 의사결정나무의 결정 규칙

- 분리 기준(Split Criterion)
 - 어떤 특성(변수)을 사용해 데이터를 분할할지를 결정하는 것으로, 정보 이득(Information Gain), 지니 지수, 엔트로피 지수 등을 사용함
 - 불확실성이 낮아지는 방향, 불순도가 낮아지는 방향, 즉 순수도가 높아지는 방향으로 분리
- 정지 규칙(Stopping Rule)
 - 더 이상 분리가 일어나지 않고 현재의 마디가 최종 마디가 되도록 하는 규칙
 - 트리가 지나치게 깊어지거나 과대적합(Overfitting)되는 것을 방지할 수 있음

예시

 - 노드에 속한 최소 샘플 수가 일정 개수 미만일 때 더 이상 분할을 수행하지 않도록 함
 - 트리의 최대 깊이가 일정 수준 이상이 되면 멈춤
- 가지치기 규칙(Pruning Rule)
 - 생성된 의사결정나무를 단순화하는 프로세스로 불필요한 분기를 제거하여 모델의 일반화 능력을 향상시키는 것
 - 복잡한 트리를 간단하게 만들어 과대적합을 방지하고 데이터에 대한 지나친 적합을 줄여줌
 - 의사결정나무는 가지치기의 비용 함수(Cost Function)를 최소화 하는 분기를 찾아내도록 학습함

2 분류용 불순도 측정 지표

- 지니 지수(Gini Index): 불순도 측정 지표로 그 값이 작을수록 순수도가 높은 것

$$\begin{aligned} \text{Gini}(T) &= 1 - \sum \left(\frac{\text{각 범주별 수}}{\text{전체 수}} \right)^2 \\ &= 1 - \sum_{i=1}^k P_i^2 \end{aligned}$$

- 엔트로피 지수(Entropy Measure)

$$\text{Entropy}(T) = - \sum_{i=1}^k P_i \log_2 P_i$$

- 불순도 측정 지표로 그 값이 작을수록 순수도가 높은 것
- 확률이 0.5인 경우($P=0.5$) 불순도가 가장 높은 상태이며, 이때의 Entropy는 1이 됨
- 카이제곱 통계량의 유의확률(p-value)
 - p-value가 가장 작은 값을 갖는 방법을 선택
 - p-value가 작을수록 집단 간 분포가 동일하지 않은, 이질성이 높은 상태인 것을 의미

최빈종 노른자

43

앙상블(Ensemble)모형

1 배깅(Bagging, Bootstrap AGGREGatING)

- 서로 다른 훈련 데이터 샘플로 훈련하며 서로 같은 알고리즘을 사용하는 방법
- 원 데이터에서 중복을 허용하는, 같은 크기의 표본을 여러 번 단순 임의 복원 추출하여 각 표본에 대해 모델을 생성하는 기법
- 여러 모델이 병렬로 학습하며 그 결과를 집계하는 방식으로, 같은 데이터가 여러 번 추출될 수도 있고 어떤 데이터는 추출되지 않을 수 있음

2 부스팅(Boosting)

- 이전 모델의 결과에 따라 다음 모델 표본 추출에서 분류가 잘못된 데이터에 가중치(weight)를 부여하여 표본을 추출함
- 여러 모델이 순차적으로 학습
- 맞추기 어려운 문제를 맞추는 데 초점이 맞춰져 있고, 다른 앙상블 기법에 비해 이상값(Outlier)에 민감함
- 대표적 알고리즘: Ada Boosting, Gradient Boosting(XGBoost, Light GBM) 등

최빈종 노른자

44

인공신경망

인공신경망(ANN)	분류, 예측 모두 가능, 입력층, 은닉층, 출력층으로 구성
Bias, variance	Overfitting: Low Bias High Variance(= 유연성 크다, 복잡도 높다)
신경망 활성화 함수	sigmoid(2개, 0~1), softmax(3개 이상의 범주), tanh(-1~1)
은닉층 노드 수	• 많으면: 과적합 문제 발생, 레이어가 많아지면 기울기 소실 문제 • 적으면: 과소적합 문제 발생, 복잡한 의사결정 경계를 만들 수 없음
기울기 소실	다층신경망에서 역전파 알고리즘이 입력층으로 갈수록 Gradient가 점차적으로 작아져 0에 수렴하여, weight가 업데이트 되지 않는 현상

1 오분류표를 사용하여 계산하는 평가 지표

구분		예측		TRUE: 귀무가설 기각(차이 있음) FALSE: 귀무가설 채택(차이 없음)
		TRUE (Positive)	FALSE (Negative)	
실제	TRUE (Positive)	TP	FN (2종 오류)	Sensitivity, Recall, TP Rate = $\frac{TP}{TP+FN}$ FN Rate = $\frac{FN}{TN+FN}$
	FALSE (Negative)	FP (1종 오류)	TN	Specificity = $\frac{TN}{TN+FP}$ FP Rate = $\frac{FP}{TN+FP}$ · 1-Specificity
Error Rate: $\frac{FP+FN}{TP+TN+FP+FN}$		Precision: $\frac{TP}{TP+FP}$	실Sen 예Pre	Accuracy: $\frac{TP+TN}{TP+TN+FP+FN}$
		F1 Score = $\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$		

더 보기

- FP → 1종 오류(P에 위에서 아래로 굿기 1회 포함)
- FN → 2종 오류(N에 위에서 아래로 굿기 2회 포함)



2 F_β Score

- F_β 는 뒤의 β 값에 따라 재현율에 가중치를 두는 방식으로, 재현율에 정밀도의 β 배 만큼 가중치를 부여하는 것
- F_2 의 경우 재현율에 2배의 가중치를 부여하고, $F_{0.5}$ 의 경우 정밀도에 2배의 가중치를 부여하게 됨
- $F_\beta = (1 + \beta^2) \times \frac{\text{precision} \times \text{recall}}{(\beta^2 \times \text{precision}) + \text{recall}}$, $F_2 = (1 + 2^2) \times \frac{\text{precision} \times \text{recall}}{(2^2 \times \text{precision}) + \text{recall}}$

1 계층적 군집(Hierarchical Clustering)의 특징

- 가장 유사한 개체를 묶어 나가는 과정을 반복하여 원하는 개수의 군집을 형성하는 방법
- 유사도 판단은 두 개체 간의 거리에 기반하므로 거리 측정에 대한 정의가 필요함
- 거리: 유클리드, 맨해튼, 민코프스키, 마할라노비스 등
- 이상값에 민감함(거리에 기반하는 경우 이상값에 민감한 특징을 갖게 됨)
- 사전에 군집 수 k 를 설정할 필요가 없는 탐색적 모형
- 군집을 형성하는 데 매 단계에서 지역적 최적화를 수행해 나가는 방법을 사용하므로 그 결과가 전역적인 최적해라고 볼 수 없음
- 병합적 방법에서 한 번 군집이 형성되면 군집에 속한 개체는 다른 군집으로 이동할 수 없음
- hclust() 함수, cluster 패키지의 agnes(), mclust() 함수 사용

2 수학적 거리의 종류



3 계층적 군집: 응집형(병합 군집) 군집의 종류

최단 연결법(Single Linkage Method, 단일 연결법)	두 군집 사이의 거리는 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최솟값 으로, 두 관측값을 연결
최장 연결법(Complete Linkage Method, 완전 연결법)	두 군집 사이의 거리는 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최댓값 으로, 두 관측값을 연결
중심 연결법(Centroid Linkage Method)	• 두 군집의 중심 간의 거리를 측정하여, 중심끼리 연결 • 두 군집이 결합될 때 새로운 군집의 평균은 가중평균을 통해 구함
평균 연결법(Average Linkage Method)	• 모든 항목에 대한 거리 평균을 구하면서 군집화함 • 계산량이 많아질 수 있음
와드 연결법(Ward Linkage Method)	• 계층적 군집 내의 오차(편차) 제곱합(Error Sum of Square)에 기초하여 군집을 수행하는 군집 방법 • 크기가 비슷한 군집끼리 병합하는 경향이 있음

최빈분류

49

연관 분석(Association Analysis)

1 연관 규칙 측정지표

규칙 표기: $A \rightarrow B$	if A then B $\rightarrow$ A가 팔리면 B가 같이 팔린다.
--------------------------	---

• 지지도(Support)

$$P(A \cap B) = \frac{A \text{와 } B \text{가 동시에 포함된 거래 수}}{\text{전체 거래 수}}$$

- 전체 거래 항목 중 차지하는 비율을 통해 해당 연관 규칙이 얼마나 의미가 있는 것인지를 확인함
- 전체 거래 항목 중 상품 A와 상품 B를 동시에 포함하여 거래하는 비율

• 신뢰도(Confidence)

$$P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{A \text{와 } B \text{가 동시에 포함된 거래 수}}{A \text{가 포함된 거래 수}}$$

- 상품 A를 구매했을 때 상품 B를 구매할 확률이 어느 정도 되는지 확인함
- 상품 A를 포함하는 거래 중 A와 B가 동시에 거래되는 비율

• 향상도(Lift)

$$\begin{aligned} \frac{P(B|A)}{P(B)} &= \frac{P(A \cap B)}{P(A) \times P(B)} = \frac{\text{상품 A의 거래 중 상품 B가 포함된 거래의 비율}}{\text{전체 상품 거래 중 상품 B가 거래된 비율}} \\ &= \frac{A \text{와 } B \text{가 동시에 일어난 확률}}{A, B \text{가 독립된 사건일 때 } A, B \text{가 동시에 일어날 확률}} \end{aligned}$$

- A가 주어지지 않았을 때 B의 확률 대비, A가 주어졌을 때 B의 확률 증가 비율
- 품목 B를 구매한 고객 대비, 품목 A를 구매한 후 품목 B를 구매하는 고객에 대한 확률

2 향상도 해석

